

Streszczenie

Modele głębokiego uczenia osiągają wysoką dokładność w automatycznej klasyfikacji arytmii serca na podstawie sygnałów EKG, jednak ich wdrożenie kliniczne pozostaje ograniczone z uwagi na brak wiarygodnych mechanizmów uzasadniania decyzji, słabą kalibrację prawdopodobieństwa predykcji oraz wrażliwość na zmiany domeny (np. różne szpitale, urządzenia rejestrujące, populacje pacjentów). Projekt adresuje trzy komplementarne aspekty zaufanej AI: (1) wyjaśnialność predykcji przy użyciu metod SHAP, LIME i Grad-CAM, (2) kalibrację niepewności modeli — mierzoną przez ECE, Brier Score i reliability diagrams — przy zastosowaniu Temperature Scaling i Conformal Prediction, oraz (3) odporność na zmianę domeny testowaną na zbiorach danych z różnych szpitali i krajów.[1 - 4]

Dane treningowe i walidacyjne będą pochodzić z zbioru PTB-XL (21 801 rekordów EKG, PhysioNet, CC BY 4.0), natomiast do testu uogólnienia zostaną użyte dwa zewnętrzne zbiory: Chapman-Shaoxing (10 646 pacjentów, ChapmanUniversity/Shaoxing People's Hospital, CC BY 4.0) oraz St. Petersburg INCART (75 nagrań, Open Data Commons Attribution). Porównane zostaną modele: regresja logistyczna, Random Forest, 1D-ResNet i Transformer. Projekt ma potencjał publikacyjny jako kompleksowy benchmark zaufanej AI dla danych biomedycznych czasowych, adresujący lukę badawczą dotyczącą łącznej oceny wyjaśnialności, kalibracji i generalizacji domeny w jednym protokole eksperymentalnym.[3],[5-10]

Uzasadnienie naukowe

Kontekst i luka badawcza

Automatyczna interpretacja EKG jest obszarem, w którym AI może ratować życie — arytmie takie jak migotanie przedsionków (AF) czy blok serca są śmiertelne przy późnym rozpoznaniu. Pomimo wysokiej dokładności klasyfikatorów głębokiego uczenia (np. $AUC > 0.96$ dla PTB-XL), ich kliniczne wdrożenie napotyka fundamentalne bariery, które dotyczą trzech aspektów zaufanej AI:[1 1]

Aspekt 1 — Wyjaśnialność modelu. Metody SHAP i Grad-CAM dominują w literaturze jako narzędzia XAI dla EKG, ale brakuje systematycznych badań porównawczych ich stabilności przy zaszumionych danych wejściowych. Recenzja z 2025 roku wskazuje, że „większość prac jest unimodalna i skupiona na jednym typie danych”, a „obecne narzędzia tylko częściowo wykrywają bias demograficzny”. Istotną luką jest brak porównania stabilności wyjaśnień (fidelity, consistency) między architekturami modeli.[7,12]

Aspekt 2 — Kalibracja i kwantyfikacja niepewności. Nowoczesne sieci neuronowe są strukturalnie przekalibrowane (overconfident). Klasyczna metoda Temperature Scaling jest skuteczna w warunkach tej samej domeny, lecz jej zachowanie przy zmianie

domeny jest mało zbadane. Conformal Prediction zapewnia gwarancje pokrycia (coverage guarantees), lecz wzajemne oddziaływanie Temperature Scaling i CP ujawnione w ICML 2025 wskazuje na nieoczekiwane kompromisy — co jest nową, aktualną luką badawczą.[2],[13-15]

Aspekt 3 — Odporność na zmianę domeny Dane EKG z różnych szpitali różnią się pod względem demografii pacjentów, urządzeń pomiarowych i procedur etykietowania. Praca Ballasa i Diou (2023) stworzyła otwarty benchmark DG dla EKG/EEG, lecz nie obejmuje jednoczesnej oceny kalibracji i wyjaśnialności po zmianie domeny — to właśnie jest luka, którą adresuje niniejszy projekt.[1],[3,4],[16]

Kontekst regulacyjny. Zgodnie z EU AI Act (2024/1689), systemy AI do diagnostyki medycznej kwalifikują się jako systemy wysokiego ryzyka i podlegają wymogom wyjaśnialności, jakości danych i nadzoru ludzkiego. Projekt dostarcza narzędzi metodologicznych do oceny tych wymogów w praktyce.[17],[18]

Nowatorstwo projektu

Dotychczasowe prace koncentrują się na jednym aspekcie zaufanej AI w izolacji. Niniejszy projekt jako pierwszy proponuje **jednoczesną, zintegrowaną ocenę wyjaśnialności, kalibracji i odporności na domain shift** w ujednoliconym protokole eksperymentalnym, stosując ten protokół do wielolabelowej klasyfikacji EKG na zbiorze danych z heterogenicznych instytucji. Taki protokół ma wartość zarówno metodologiczną (replikowalny benchmark), jak i praktyczną (ocena gotowości do wdrożenia klinicznego).

Dane wykorzystane w projekcie

Tabela Zbiorów Danych

Parametr Nazwa	PTB-XL PTB-XL ECG Dataset v1.0.3	Chapman-Shaoxing A large scale 12-lead ECG database for arrhythmia study v1.0.0	INCART St. Petersburg INCART 12-lead Arrhythmia Database v1.0.0
Instytucja	PTB / Charité Berlin / Fraunhofer HHI	Chapman University & Shaoxing People's Hospital & Ningbo First Hospital	St. Petersburg Institute of Cardiological Technics
Strona źródłowa	https://physionet.org/content/ptb-xl/1.0.3/	https://physionet.org/content/ecg-arrhythmia/1.0.0/	https://physionet.org/content/incartdb/1.0.0/
Link do pobrania Typ danych	https://physionet.org/files/ptb-xl/1.0.3/ Sygnały EKG 12-odprowadzeniowe, szeregi czasowe	https://physionet.org/files/ecg-arrhythmia/1.0.0/ Sygnały EKG 12-odprowadzeniowe	https://physionet.org/files/incartdb/1.0.0/ Sygnały EKG 12-odprowadzeniowe, Holter
Format	WFDB (.hea + .dat), CSV z metadanymi	WFDB (.hea + .dat), CSV z etykietami	WFDB (.hea + .dat)
Wielkość Pacjenci	21 801 nagrań (3,18 GB) 18 869	45 152 nagrań (5,46 GB) 10 646	75 nagrań 30-minutowych 32 (Holter)
Częstotliwość Długość nagrania	500 Hz (+ wersja 100 Hz) 10 s	500 Hz 10 s	257 Hz 30 min
Klasy docelowe	71 etykiet SCP-ECG → 5 nadklas diagnostycznych	11 rytmów + 67 schorzeń sercowych	Adnotacje uderzeń serca (beat annotations), >175 000
Opis etykiet	Adnotowane przez 2 kardiologów, etykiety SCP-ECG, 5 nadklas: NORM, MI, STTC, CD, HYP	Etykietowane przez ekspertów klinicznych, SNOMED-CT	Adnotacje uderzeń przez ekspertów

Licencja	Creative Commons Attribution 4.0 (CC BY 4.0)[19] Crea	tive Commons Attribution 4.0 (CC BY 4.0)[20] Open Dat	a Commons Attribution License v1.0[21]
Cytowanie	Wagner et al., Scientific Data, 2020[6]; PhysioNet DOI: 10.13026/kfzx-aw45[22] Zheng et	al., Scientific Data, 2020[9]; PhysioNet DOI: 10.13026/wgex-er52[23] PhysioNet DOI: 1	0.13026/C2108F[24]
Przeznaczenie	Trening, walidacja, test (wewnętrzny)	Test uogólnienia (zewnętrzny, inny szpital)	Test uogólnienia (dodatkowy, inna populacja)

Podział danych

Dane treningowe:

PTB-XL udostępnia sugerowany podział na 1 0 foldów stratyfikowanych w metadanych (strat_fold). Należy użyć foldów 1 –8 (ok. 1 7 4 4 1 rekordów) jako danych treningowych. Ten zestaw pochodzi z jednej instytucji (PTB Berlin), co stanowi czystą domenę treningową.

Dane walidacyjne:

Fold 9 PTB-XL (ok. 2 1 7 5 rekordów) — wyłącznie do strojenia hiperparametrów, wyboru modelu i uczenia parametrów kalibracji (Temperature Scaling). Nie można używać tych danych do ostatecznej oceny.

Dane testowe (wewnętrzne):

Fold 1 0 PTB-XL (ok. 2 1 8 5 rekordów) — jedyny zestaw używany do ostatecznego raportowania metryk klasyfikacji i kalibracji na danych z tej samej domeny. Należy go odizolować i nie zaglądać do niego przed zakończeniem treningu i kalibracji.

Dane zewnętrzne (test uogólnienia / domain shift):

- Chapman-Shaoxing: 4 5 1 5 2 nagrań z chińskich szpitali — całkowicie odrębna populacja pacjentów, urządzenia i warunki kliniczne niż PTB. Stosować do oceny odporności na zmianę domeny. Ze względu na rozbieżność klas (np. brak klasy MI w Chapman-Shaoxing) analiza ograniczona do wspólnych klas (NORM, AF, CD).[2 5]
- INCART (St. Petersburg): 7 5 nagrań Holter — różna długość nagrania, inna populacja. Stosować do testu na wyjątkowym typie danych.

Zabezpieczenie przed przeciekami danych (data leakage):

- Podział musi być oparty na pacjentach (ecg_id → patient_id), nie na nagraniach. PTB-XL zawiera po kilka nagrań od jednego pacjenta — nagrania tego samego pacjenta muszą trafić do jednego foldu.
- Normalizacja (mean/std) wyliczana wyłącznie na zbiorze treningowym, aplikowana do walidacji i testu.
- Augmentacja stosowana wyłącznie podczas treningu.
- Parametry Temperature Scaling uczone wyłącznie na zbiorze walidacyjnym.

Problem badawczy i hipotezy

Główny Problem Badawczy

Czy modele głębokiego uczenia do klasyfikacji arytmii EKG spełniają kryteria zaufanej AI — rozumianej jako jednoczesna wysoka skuteczność klasyfikacji, dobrze

skalibrowana niepewność predykcji, stabilne i klinicznie sensowne wyjaśnienia oraz zachowanie tych właściwości po zmianie domeny — i jak te wymiary korelują ze sobą?

Hipotezy Badawcze

H1 (Kalibracja): Modele głębokiego uczenia (ResNet, Transformer) będą wykazywać istotnie wyższą wartość Expected Calibration Error (ECE) niż modele interpretowalne (Regresja Logistyczna, Random Forest) na zbiorze testowym PTB-XL Fold 1 0 , a zastosowanie Temperature Scaling zredukuje ECE modeli głębokich o co najmniej 3 0 % przy zachowaniu AUROC na porównywalnym poziomie.[1 5]

H2 (Stabilność wyjaśnień przy szumie): Mapa saliencji Grad-CAM wygenerowana dla sygnału EKG z dodanym szumem gaussowskim (SNR = 2 0 dB) będzie wykazywać istotnie niższą korelację przestrzenną z mapą dla sygnału oryginalnego w przypadku sieci ResNet niż Transformer — co oznacza, że architektury z mechanizmem uwagi generują bardziej stabilne wyjaśnienia przy degradacji danych.

H3 (Odporność na domain shift): Wartość AUROC modeli trenowanych wyłącznie na PTB-XL obniży się o więcej niż 1 0 punktów procentowych przy testowaniu na zbiorze Chapman-Shaoxing (zmiana domeny), a obniżenie ECE uzyskane przez Temperature Scaling uczony na PTB-XL nie przeniesie się na dobre wyniki kalibracji w nowej domenie.[4][1]

H4 (Conformal Prediction vs. Temperature Scaling): Conformal Prediction zapewni empirycznie gwarantowane pokrycie (coverage) na poziomie 9 0 % zarówno na zbiorze testowym PTB-XL, jak i Chapman-Shaoxing, natomiast Temperature Scaling, choć lepszy na PTB-XL, nie będzie gwarantować pokrycia po zmianie domeny — zgodnie z obserwacjami z ICML 2 0 2 5 .[1 3][2]

H5 (Korelacja wymiarów zaufania): Model o najwyższym AUROC niekoniecznie będzie modelem o najniższym ECE ani modelem generującym najbardziej stabilne wyjaśnienia — co oznacza, że metryki skuteczności klasyfikacji są niewystarczające do oceny zaufanej AI i konieczne jest wielowymiarowe podejście.

Proponowana metodologia

Przygotowanie danych

1. **Pobranie PTB-XL** z PhysioNet za pomocą wget lub biblioteki wfdb:

```
wget -r -N -c -np https://physionet.org/files/ptb-xl/1 .0 .3 /  
pip install wfdb pandas numpy scipy
```
2. **Pobranie Chapman-Shaoxing** z PhysioNet:

```
wget -r -N -c -np https://physionet.org/files/ecg-arrhythmia/1 .0 .0 /
```
3. **Kontrola integralności:** weryfikacja SHA2 5 6 według pliku SHA2 5 6 SUMS.txt dostarczonego przez PhysioNet.
4. **Wczytanie sygnałów:** biblioteka wfdb.rdsamp() dla WFDB; plik ptbxl_database.csv zawiera metadane, etykiety, patient_id i sugerowany podział foldów.
5. **Czyszczenie danych:** usunięcie nagrań z brakującymi odprowadzeniami (sprawdzić kolumnę validated_by_human); dla PTB-XL nie ma rekordów z brakującymi sygnałami.

- 6 **Normalizacja:** sygnały normalizowane per-odprowadzenie (zscore) ze statystykami z Foldu 1 –8 ; zapisać parametry do pliku.
- 7 **Augmentacja** (wyłącznie trening): losowe odwracanie polaryzacji z $p = 0.5$, przesunięcia czasowe ± 50 próbek, dodanie szumu gaussowskiego ($SNR = -30$ dB).
- 8 **Podział:** patient_id-aware split — folds 1 –8 trening, fold 9 walidacja, fold 10 test; brak mieszania pacjentów.
- 9 **Wieloetykietowe binaryzowanie:** konwersja etykiet SCP-ECG na 5 -klasowy wektor binarny przy progu diagnostycznej pewności $\geq 100\%$.

Modele bazowe

Model	Biblioteka	Uzasadnienie
Regresja Logistyczna	scikit-learn	Interpretowalne baseline, dobrze skalibrowane a priori
Random Forest (100 drzew)	scikit-learn	Klasyczny ensemble, feature importance jako proto-XAI
XGBoost	xgboost	Silny gradient boosting, wbudowana feature importance

Cechy dla modeli bazowych: statystyki sygnału per odprowadzenie (mean, std, min, max, kurtoza, skośność, energia, moc FFT w pasmach 0 –15 Hz i 15 –40 Hz) — łącznie ~ 96 cech.

Modele główne

Model	Architektura	Uzasadnienie
1 D-ResNet (ResNet-34 adapted)	Bloki rezydualne na sygnałach 1D	Aktualny SOTA na PTB-XL[11], umożliwia Grad-CAM
Transformer (1D PatchTST)	Self-attention na segmentach sygnału	Generuje naturalne mapy uwagi, testowane w domenach czasowych
Lightweight CNN (~20k params)	Lightweight CNN zaproponowany w[11] depl	Możliwość edge oyment, Grad-CAM, mała liczba parametrów

Wszystkie modele: PyTorch 2.0.x, Adam, $lr = 1e-3$, scheduler cosine annealing, early stopping na walidacyjnym AUROC, batch= 64 , 50 epok.

Metody zaufanej AI

Wyjaśnialność (XAI):

- **SHAP (DeepExplainer / KernelExplainer)** [biblioteka: shap] — wartości SHAP perodprowadzenie, per-próbka; dla ResNet użyć GradientExplainer[26]
- **LIME (LocalInterpretableModelAgnosticExplanations)** [biblioteka: lime] — segmenty sygnału jako cechy
- **Grad-CAM** [biblioteka: pytorch-grad-cam] — mapy aktywacji dla CNN i ResNet[11][12]
- **Integrated Gradients** [biblioteka: captum] — dla Transformer

Ocena wyjaśnień: **Fidelity** (korelacja wyjaśnienia z perturbacją wejścia), **Consistency** (pokrywanie się wyjaśnień dla podobnych przykładów), **Input Faithfulness** (drop in performance po maskowaniu top-k cech).

Kalibracja i kwantyfikacja niepewności:

- **Temperature Scaling** (post-hoc, uczony na Foldzie 9) — `pip install netcal[1 4 ][1 5 ]`
- **Monte Carlo Dropout** ($p = 0.1, 0.5, 0$ przejść do przodu podczas inferencji)
- **Deep Ensembles** (5 modeli ResNet z różną inicjalizacją)
- **Conformal Prediction (Adaptive Prediction Sets — APS)** [biblioteka: `nonconformist` lub `mapie`][2 7][2]

Testy odporności:

- Szum gaussowski (SNR = 1 0 , 1 5 , 2 0 , 2 5 , 3 0 dB) dodany do sygnałów testowych
- Brakujące odprowadzenia: zerowanie 1 , 2 , 4 z 1 2 odprowadzeń losowo
- Domain shift: testowanie na Chapman-Shaoxing i INCART bez doszkalania

Detekcja OOD (out-of-distribution):

- Energy score (Liu et al., 2 0 2 0) — stosunek energii softmax
- Maximum Softmax Probability (MSP) jako baseline
- Mahalanobis distance w przestrzeni osadzeń

Metryki Oceny

Wymiar	Metryki
Skuteczność	Macro-AUROC, Macro-AUPRC, Balanced Accuracy, Macro-F1 , Recall per klasa
Kalibracja	Expected Calibration Error (ECE), SmoothECE[2 8][2 9], Brier Score, Reliability Diagram, MCE
Niepewność	Prediction interval coverage (Conformal), prediction set size (APS), correlation uncertainty-accuracy
Wyjaśnialność	Fidelity, Consistency (SHAP stability), kliniczne dopasowanie (obszar QRS, T-wave)
Odporność	Robustness Drop (AUROC original - AUROC noisy), ECE po domain shift, AUROC na Chapman-Shaoxing
OOD	AUROC OOD detection (in-dist vs out-dist), FPR@9 5 %TPR

Zadania do reaizacji

Etap 1 — Przegląd literatury

- **Cel:** Zrozumienie state-of-the-art w zaufanej AI i klasyfikacji EKG
- **Działania:** Przeczytać i sporządzić notatki z co najmniej 1 5 prac (lista zaproponowana w Sekcji 1 2); sporządzić tabelę metod XAI stosowanych do EKG[7][3 0][1 2]
- **Rezultat:** Dokument przeglądowy (3 –5 stron) z tabelą porównawczą

- **Kryterium zaliczenia:** Akceptacja przez prowadzącego; pokrycie co najmniej 5 prac z listy obowiązkowej

Etap 2 — Wybór i Weryfikacja Danych

- **Cel:** Potwierdzenie dostępności, licencji i struktury danych
- **Działania:** Pobranie PTB-XL i Chapman-Shaoxing z PhysioNet; weryfikacja SHA2 5 6 ; sprawdzenie licencji CC BY 4 .0 ; eksploracja metadanych (ptb_xl_database.csv)[6][2 2]
- **Rezultat:** Raport weryfikacyjny: liczba rekordów, rozkład klas, brakujące dane
- **Kryterium zaliczenia:** Poprawne wczytanie co najmniej 1 0 0 sygnałów; wydrukowany rozkład klas dla 5 nadklas

Etap 3 — Przygotowanie Środowiska Obliczeniowego

- **Cel:** Działające środowisko Python z GPU
- **Działania:** Conda environment z PyTorch 2 .x, scikit-learn, wfdb, shap, lime, captum, pytorch-grad-cam, netcal, mapie; repozytorium Git na GitHub/GitLab
- **Rezultat:** requirements.txt, README.md, skrypt setup_env.sh
- **Kryterium zaliczenia:** Skrypt treningu prostego modelu CNN kończy się bez błędów

Etap 4 — Eksploracyjna Analiza Danych (EDA)

- **Cel:** Zrozumienie charakterystyk danych
- **Działania:** Wizualizacja losowych nagrań EKG; histogram długości, amplitud; macierz współwystępowania etykiet; analiza rozkładu demograficznego (wiek, płeć); porównanie statystyk PTB-XL vs Chapman-Shaoxing
- **Rezultat:** Notebook Jupyter z wizualizacjami i wnioskami
- **Kryterium zaliczenia:** Identyfikacja co najmniej 3 różnic między PTB-XL a Chapman-Shaoxing

Etap 5 — Przygotowanie Zbiorów Treningowych/Walidacyjnych/Testowych

- **Cel:** Czysty, odizolowany podział danych
- **Działania:** Implementacja patient-aware split (folds 1 –8 / fold 9 / fold 1 0); normalizacja; augmentacja; weryfikacja braku przecieku (test: brak wspólnych patient_id między zbiorami)
- **Rezultat:** Skrypt prepare_data.py + pliki train.npy, val.npy, test.npy, test_external.npy (Chapman)
- **Kryterium zaliczenia:** Zero wspólnych patient_id między train/val/test (assert)

Etap 6 — Implementacja Modeli Bazowych

- **Cel:** Działające modele baseline z metrykami
- **Działania:** Ekstrakcja cech sygnału; trening i ewaluacja LR, RF, XGBoost; tabela wyników z AUROC, F1 , Brier Score
- **Rezultat:** Skrypt train_baseline.py + tabela wyników
- **Kryterium zaliczenia:** Macro-AUROC ≥ 0.75 dla co najmniej jednego modelu

Etap 7 — Implementacja Modeli Głównych

- **Cel:** Działające modele DL z saved weights
- **Działania:** Implementacja 1 D-ResNet i Transformer; trening z early stopping; zapisanie najlepszych wag; krzywe uczenia
- **Rezultat:** Skrypt train_deep.py, pliki .pt z wagami, krzywe straty i AUROC
- **Kryterium zaliczenia:** Macro-AUROC na walidacji ≥ 0.85

Etap 8 — Ocena Skuteczności Klasyfikacji

- **Cel:** Kompletna tabela wyników na teście
- **Działania:** Ewaluacja wszystkich modeli na Foldzie 10 PTB-XL; macierze pomyłek; krzywe ROC per klasa; AUROC, F1, Recall per klasa
- **Rezultat:** Tabela porównawcza wszystkich modeli, wykresy ROC
- **Kryterium zaliczenia:** Kompletna tabela z 6 modelami i 5 metrykami

Etap 9 — Ocena Kalibracji i Niepewności

- **Cel:** Pomiar i poprawa kalibracji
- **Działania:** Wyliczenie ECE, Brier Score dla wszystkich modeli; Reliability Diagrams; implementacja Temperature Scaling na Foldzie 9; ponowna ewaluacja po kalibracji; Conformal Prediction APS na Foldzie 10 [2]
- **Rezultat:** Reliability Diagrams (przed/po), tabela ECE/Brier, tabela coverage CP
- **Kryterium zaliczenia:** Reliability Diagram pokazuje poprawę kalibracji po Temperature Scaling

Etap 10 — Analiza Wyjaśnialności

- **Cel:** Wyjaśnienia predykcji i ocena ich jakości
- **Działania:** SHAP dla modeli bazowych i ResNet; Grad-CAM dla ResNet i CNN; Integrated Gradients dla Transformer; wizualizacja na 5 przykładach per klasa; test stabilności (SHAP dla sygnału oryginalnego vs zaszumionego) [1, 1]
- **Rezultat:** Wizualizacje wyjaśnień, tabela stabilności (korelacja Spearman rank), raport klinicznej interpretowalności
- **Kryterium zaliczenia:** Wyjaśnienia dla co najmniej 3 modeli; test stabilności z metryką Spearman r

Etap 11 — Test Odporności na Zakłócenia

- **Cel:** Pomiar degradacji wydajności przy szumie i brakujących odprowadzeniach
- **Działania:** Ewaluacja wszystkich modeli na sygnałach z szumem (SNR = 10, -3, 0 dB, 5 poziomów); test z maskowaniem 1, 2, 4 odprowadzeń; obliczenie Robustness Drop = AUROC(oryginalny) – AUROC(zaszumiony)
- **Rezultat:** Wykres degradacji AUROC vs SNR; tabela Robustness Drop per model
- **Kryterium zaliczenia:** Kompletna tabela dla co najmniej 2 modeli i 3 poziomów szumu

Etap 12 — Test Uogólnienia na Danych Zewnętrznych

- **Cel:** Ocena domain shift

- **Działania:** Ewaluacja najlepszych 3 modeli na Chapman-Shaoxing (wspólne klasy: NORM, AF, Conduction Disturbance); porównanie AUROC i ECE PTB-XL vs Chapman; testy OOD detection (Energy Score, MSP)[3 1][3 2][2 5]
- **Rezultat:** Tabela domain shift drop, wykresy ECE inter-domain, analiza OOD
- **Kryterium zaliczenia:** Raport z domain shift drop dla 3 modeli; próba OOD detection

Etap 1 3 — Analiza Błędów

- **Cel:** Jakościowe zrozumienie pomyłek modeli
- **Działania:** Identyfikacja FN i FP dla klasy MI; analiza wzorców błędnych predykcji (wiek, płeć, comorbidity); sprawdzenie korelacji niepewności modelu z błędnymi predykcjami
- **Rezultat:** Error analysis notebook, macierze pomyłek per model, case studies
- **Kryterium zaliczenia:** Co najmniej 10 szczegółowo opisanych przypadków błędnych predykcji

Etap 1 4 — Repozytorium Kodu i Dokumentacja

- **Cel:** Reprodukowalne repozytorium
- **Działania:** Struktura repozytorium: data/, models/, experiments/, results/, notebooks/; plik README.md z instrukcją instalacji i reprodukcji; requirements.txt; komentarze Docstring; skrypt run_all.sh
- **Rezultat:** Publiczne repozytorium GitHub z README, requirements i pełnym kodem
- **Kryterium zaliczenia:** Reprodukacja pełnego eksperymentu baseline przez osobę trzecią

Etap 1 5 — Przygotowanie Wyników do Publikacji

- **Cel:** Materiały w standardzie publikacyjnym
- **Działania:** Przygotowanie tabel LaTeX, wykresów w matplotlib/seaborn (dpi= 300), szkic sekcji Methods + Results artykułu (3 –5 stron)
- **Rezultat:** Szkic artykułu lub pełny raport techniczny w formacie IEEE/Springer
- **Kryterium zaliczenia:** Akceptacja szkicu przez prowadzącego

Oczekiwane wyniki

Po zakończeniu projektu powinny powstać następujące materiały:

Tabele wyników:

- 1 . Tabela porównawcza 6 modeli $\times$ 5 metryk skuteczności (AUROC, F1 , Recall, AUPRC, Balanced Accuracy) na PTB-XL Fold 1 0
- 2 . Tabela kalibracji: ECE przed i po Temperature Scaling, Brier Score, MCE dla każdego modelu
- 3 . Tabela domain shift: AUROC i ECE dla PTB-XL vs Chapman-Shaoxing per model
- 4 . Tabela Robustness Drop: AUROC(original) – AUROC(noisy) per model i per SNR

5 . Tabela Conformal Prediction: empiryczne pokrycie i średni rozmiar zbioru predykcji przy $\alpha = 0.1$

Wykresy:

- Krzywe ROC (macro + per klasa) dla wszystkich modeli
- Reliability Diagrams (przed i po kalibracji) dla każdego modelu
- Wykres degradacji AUROC vs SNR (liniowy, per model)
- Wykres redukcji ECE po Temperature Scaling (bar chart)
- t-SNE/UMAP przestrzeni osadzeń ResNet dla PTB-XL i Chapman-Shaoxing (wizualizacja domain shift)

Mapy wyjaśnialności:

- SHAP bar charts (top-20 cech) dla LR i RF
- Grad-CAM nałożone na sygnał EKG dla ResNet — co najmniej 3 przykłady per klasa
- Porównanie wyjaśnień oryginalnych vs zaszumionych (stabilność)
- Integrated Gradients dla Transformer

Analiza przypadków:

- Co najmniej 10 fałszywie negatywnych przypadków MI z wyjaśnieniami
- Co najmniej 5 przypadków wysokiej niepewności modelu (Conformal Prediction: pusty lub duży zbiór predykcji)

Wnioski naukowe:

- Czy głębsze modele są lepiej skalibrowane po Temperature Scaling niż modele płytkie?
- Czy Temperature Scaling jest wystarczający jako metoda kalibracji przy domain shift?
- Czy Conformal Prediction zapewnia gwarantowane pokrycie na zewnętrznym zbiorze?
- Który model oferuje najlepszy kompromis skuteczność–kalibracja–wyjaśnialność?

Dane i Zbiory Danych

1. **Wagner, P., Strodthoff, N., Bousseljot, R.-D., et al. (2020)** PTB-XL, a large publicly available ECG dataset. *Scientific Data*, 7, 1–5. <https://doi.org/10.1038/s41597-020-00616-6> — Podstawowa publikacja opisująca PTB-XL; wymagana do cytowania przy użyciu zbioru[6]
2. **Zheng, J., Guo, H., & Chu, H. (2022)** A large scale 12-lead electrocardiogram database for arrhythmia study (version 1.0.0). *PhysioNet*. <https://doi.org/10.13026/wgex-er52> — Zbiór Chapman-Shaoxing; do cytowania przy teście domain shift[23][9]
3. **St. Petersburg Institute of Cardiological Technics.** St Petersburg INCART 12-lead Arrhythmia Database. *PhysioNet*. <https://physionet.org/content/incartdb/1.0.0/> — Zbiór INCART; do testu uogólnienia i OOD[10]
4. **Wagner, P., Strodthoff, N., et al. (2022)** PTB-XL+, a comprehensive ECG feature dataset. *Scientific Data*. <https://doi.org/10.1038/s41597-022-0827-8> — Rozszerzenie PTB-XL o cechy ECG; opcjonalnie do analizy cech[33]

Trustworthy AI — Przeglądy i Frameworki

5. **Bellotti, A., & Zhao, X. (2025)** Conformal Prediction and Trustworthy AI. *arXiv:2508.06884* — Aktualny (2025) przegląd roli Conformal Prediction w trustworthy AI[2]
6. **Mittal, et al. (2024)** Responsible machine learning datasets emphasizing fairness, privacy and regulatory norms. *Nature Machine Intelligence*. — Audyt ponad 100 zbiorów danych pod kątem fairness i privacy[34]
7. **EU AI Act (2024)** Regulation of the European Parliament. <https://artificialintelligenceact.eu/article/6/> — Wymogi regulacyjne dla systemów wysokiego ryzyka; kontekst projektu[18]

Wyjaśnialność AI (XAI)

8. **Dabai, U.S., et al. (2024)** Bridging the AI Explainability Gap in Cardiac Imaging: A Review of Hybrid Approaches Using Grad-CAM and SHAP. *IJISAE*. — Przegląd SHAP + Grad-CAM w cardiac AI[12]

9. **Arttime, O., et al. (ACM 2025).** Multi-Level Explainable AI for ECG-Based Atrial Fibrillation Detection. <https://dl.acm.org/doi/10.1145/3761712.3761721> — *Multi-level XAI (LIME, SHAP, Grad-CAM) dla AF; bezpośrednio relevant*[30]
10. **Linardatos, P., et al. (2021).** Explainable AI: A Review of Machine Learning Interpretability Methods. *Entropy*, 23(1), 18. — *Klasyczny przegląd metod XAI; punkt odniesienia*
11. **Ribeiro, M.T., et al. (2016).** “Why should I trust you?”: Explaining the predictions of any classifier. *KDD 2016*. — *Oryginalny artykuł LIME*
12. **Lundberg, S.M., & Lee, S.I. (2017).** A unified approach to interpreting model predictions. *NIPS 2017*. — *Oryginalny artykuł SHAP*

Kalibracja i Kwantyfikacja Niepewności

13. **Guo, C., Pleiss, G., Sun, Y., & Weinberger, K.Q. (2017).** On Calibration of Modern Neural Networks. *ICML 2017*. arXiv:1706.04599. — *Fundamentalny artykuł Temperature Scaling; obowiązkowy*[15]
14. **Błasiok, J., & Nakkiran, P. (2024).** SmoothECE: Principled Reliability Diagrams via Kernel Smoothing. *ICLR 2024*. <https://github.com/apple/ml-calibration> — *Nowoczesna metryka kalibracji SmoothECE; pip install relplot*[28][29]
15. **Angelopoulos, A.N., & Bates, S. (2022).** A Gentle Introduction to Conformal Prediction and Distribution-Free Uncertainty Quantification. arXiv:2107.07511. — *Najlepsza wprowadzenie do Conformal Prediction*
16. **Gal, Y., & Ghahramani, Z. (2016).** Dropout as a Bayesian approximation. *ICML 2016*. — *Monte Carlo Dropout; wyczerpujące uzasadnienie teoretyczne*
17. **Lakshminarayanan, B., et al. (2017).** Simple and scalable predictive uncertainty estimation using deep ensembles. *NIPS 2017*. — *Deep Ensembles jako UQ baseline*
18. **Rahimi, A., et al. (2023).** Calibration in Deep Learning: A Survey of the State-of-the-Art. arXiv:2308.01222. — *Kompletny przegląd metod kalibracji*[35][36]
19. **Wang, S., et al. (2025).** On Temperature Scaling and Conformal Prediction of Deep Classifiers. *ICML 2025*. — *Najnowszy wynik: interakcja Temperature Scaling z CP; kluczowy dla H4*[13]

Domain Shift i Generalizacja

20. **Ballas, A., & Diou, C. (2023).** Towards Domain Generalization for ECG and EEG Classification: Algorithms and Benchmarks. arXiv:2303.11338. — *Otwarty benchmark DG dla biosygnatów; bezpośredni punkt odniesienia*[16][3]
21. **Yu, B., et al. (2025).** Trustworthy diagnosis of Electrocardiography signals based on out-of-distribution detection. *PLoS ONE*, 20(2), e0317900. — *OOD detection dla EKG; kluczowy dla Etapu 12*[32][31]
22. **Zhao, X., et al. (2025, Sci Rep).** Research on cross-dataset cardiac signal domain generalization and feature interpretability. *Scientific Reports*. — *Domain generalization + interpretability ECG; aktualny analog projektu*[1]

Architektury Modeli

23. **Strodthoff, N., et al. (2021).** Deep Learning for ECG Analysis: Benchmarks and Insights from PTB-XL. *IEEE JBHI*. — *Oficjalny benchmark PTB-XL; baseline dla AUROC*

- 2 4 **Marrugo, A., et al. (2 0 2 5)** Lightweight and Interpretable CNNs for Multi-Label ECG Diagnosis on the Edge. *IEEE*. — *Lightweight CNN + Grad-CAM na PTB-XL; bezpośredni wzorzec implementacji*[1 1]

Biblioteki i Narzędzia Programistyczne

- 2 5 **SHAP library:** <https://shap.readthedocs.io> — pip install shap
- 2 6 **LIME library:** <https://github.com/marcotcr/lime> — pip install lime
- 2 7 **Captum (Integrated Gradients):** <https://captum.ai> — pip install captum
- 2 8 **pytorch-grad-cam:** <https://github.com/jacobgil/pytorch-grad-cam> — pip install grad-cam
- 2 9 **netcal (Temperature Scaling, ECE):** <https://github.com/EFS-OpenSource/calibration-framework> — pip install netcal
- 3 0 **MAPIE (Conformal Prediction):** <https://github.com/scikit-learn-contrib/MAPIE> — pip install mapie
- 3 1 **WFDB (wczytywanie danych PhysioNet):** <https://github.com/MIT-LCP/wfdb-python> — pip install wfdb
- 3 2 **relplot (SmoothECE, Reliability Diagrams):** <https://github.com/apple/ml-calibration> — pip install relplot[2 8]

Literatura

- 1 [.Research on cross-dataset cardiac signal domain ...](#) - Cross-dataset modeling of electrocardiogram signals faces the dual challenges of domain shift and in...
- 2 [.\[2 5 0 8 .0 6 8 8 5 \] Conformal Prediction and Trustworthy AI in this article, we review the potential for conformal prediction to contribute to trustworthy AI be...](#)

3. [Towards Domain Generalization for ECG and EEG ...](#) - Despite their immense success in numerous fields, machine and deep learning systems have not yet bee...
4. [\[PDF\] Enhancing Cross-Hospital Generalizability of Deep Learning ...](#)
5. [PTB-XL, a large publicly available electrocardiography dataset](#) - The PTB-XL ECG dataset is a large dataset of 21801 clinical 12-lead ECGs from 18869 patients of 10 s...
6. [PTB-XL, a large publicly available electrocardiography dataset - Scientific Data](#) - Measurement(s) electrocardiography • cardiovascular system Technology Type(s) 12 lead electrocardiog...
7. [Jan Beger's Post - LinkedIn](#) - AI explainability in cardiology is progressing with proven tools like SHAP and GradCAM but newer lan...
8. ["A 12-lead Electrocardiogram Database for Arrhythmia Research ...](#) - This newly inaugurated research database for 12-lead electrocardiogram signals was created under the...
9. [A 12-lead electrocardiogram database for arrhythmia research ...](#) - This newly inaugurated research database for 12-lead electrocardiogram signals was created under the...
10. [St Petersburg INCART 12-lead Arrhythmia Database - PhysioNet](#) - Annotated ECG recordings extracted from 32 Holter records.
11. [Lightweight and Interpretable CNNs for Multi-Label ECG Diagnosis on the Edge](#) - Automated multi-label electrocardiogram (ECG) diagnosis promises accessible cardiovascular care, but...
12. [International Journal of](#)
13. [On Temperature Scaling and Conformal Prediction of Deep Classifiers](#) - 3. Temperature Scaling (TS) (Guo et al., 2017) stands out as, arguably, the most common calibration ...
14. [Neural Network Calibration - Geoff Pleiss](#) - Temperature scaling is a post-processing technique which can almost perfectly restore network calibr...
15. [\[1706.04599\] On Calibration of Modern Neural Networks - arXiv](#) - We evaluate the performance of various post-processing calibration methods on state-of-the-art archi...
16. [Towards Domain Generalization for ECG and EEG Classification: Algorithms and Benchmarks](#) - Despite their immense success in numerous fields, machine and deep learning systems have not yet bee...
17. [The EU AI Act and Medical Devices: Navigating High-Risk ...](#) - The EU AI Act entered into force in August 2024 and is set to apply gradually over the coming years....
18. [Article 6: Classification Rules for High-Risk AI Systems](#)
19. [PTB-XL, a large publicly available electrocardiography dataset 1.0.2](#)
20. [Creative Commons Attribution 4.0 International Public License](#) - The Licensor hereby grants You a worldwide, royalty-free, non-sublicensable, non-exclusive, irrevoca...
21. [Open Data Commons Attribution License v1.0 - PhysioNet](#) - terms of this License. Back to MIT-BIH Arrhythmia Database v1.0.0. PhysioNet. Maintained by the MIT ...
22. [PTB-XL, public electrocardiography dataset](#) - Kaggle is the world's largest data science community with powerful tools and resources to help you a...

23. [A large scale 12-lead electrocardiogram database for arrhythmia study](#) - This newly inaugurated research database for 12-lead electrocardiogram (ECG) signals was created und...
24. [MIT-BIH Arrhythmia Database P-Wave Annotations v1.0.0 - PhysioNet](#) - Anyone can access the files, as long as they conform to the terms of the specified license. License ...
25. [BenchMD/dataset-info.md at main - GitHub](#) - This Chapman Shaoxing Dataset consists of 10,247 EKG recordings collected from the Chapman Universit...
26. [From Prototypes to Sparse ECG Explanations: SHAP-Driven ... - arXiv](#) - Deep neural networks achieve high accuracy on multivariate time series tasks [34] . Classification m...
27. [Quantifying Deep Learning Model Uncertainty in Conformal Prediction](#) - We propose a probabilistic approach in quantifying the model uncertainty derived from the produced p...
28. [Principled Reliability Diagrams via Kernel Smoothing](#)
29. [Published as a conference paper at ICLR 2024](#)
30. [Multi-Level Explainable AI for ECG-Based Atrial Fibrillation Detection](#) - This study presents a multi-level explainable AI (XAI) framework for AFib detection, combining LIME,...
31. [Trustworthy diagnosis of Electrocardiography signals based on out ... - We propose](#) a novel trustworthy diagnosis method for ECG signals based on OOD detection. The proposed...
32. [Trustworthy diagnosis of Electrocardiography signals based on out ... - We propose](#) a novel trustworthy diagnosis method for ECG signals based on OOD detection. The proposed...
33. [PTB-XL+, a comprehensive electrocardiographic feature dataset - Scientific Data](#) - Machine learning (ML) methods for the analysis of electrocardiography (ECG) data are gaining importa...
34. [On responsible machine learning datasets emphasizing fairness, privacy and regulatory norms with examples in biometrics and healthcare - Nature Machine Intelligence](#) - There are pervasive concerns related to fairness, privacy and regulatory compliance in machine learn...
35. [Calibration in Deep Learning: A Survey of the State-of-the-Art - arXiv](#)
36. [Calibration in Deep Learning: A Survey of the State-of-the-Art](#)